Tacotron이 말을 했어요

목차

- 1. 음성합성 & Tacotron
- 2. RNN, Attention
- 3. Tacotron 분석
- 4. Appendix

1.음성합성 & Tacotron

AiFrenz 회원여러분, 반갑습니다.






음성합성 모델

전통적 음성합성

- concatenative TTS: database에 있는 음성을 합성 → 음질은 좋지만, 방대한 DB필요
- statistical parametric TTS: HMM같은 모델에 기반한 방법
 - > text analyzer, F0 generator, spectrum generator, pause estimator, vocoder
 - ➤ 음질은 좋지 못하지만, Acoustic Feature 조절 가능



Tacotron Model Architecture




Figure 1: Model architecture. The model takes characters as input and outputs the corresponding raw spectrogram, which is then fed to the Griffin-Lim reconstruction algorithm to synthesize speech.

합성 단계 Input: Text

Outputs: Mels-pectrogram(예측) → (linear) Spectrogram(예측) → Speech(Audio)

Train 단계 Inputs: Text, Mel-spectrogram, (linear) Spectrogram
Outputs: Mels-pectrogram(예측) → (linear) Spectrogram(예측) → Speech(Audio)

Tacotron 구현 Code

- keithito(2017년7월)
 - ➤ 대표적인 Tacotron 구현
 - https://github.com/keithito/tacotron
- carpedm20(2017년10월)
 - ➤ keithito 코드를 기반으로 Tacotron 모델로 한국어 생성
 - ➤ DeepVoice 2에서 제안한 Multi-Speaker 모델로 확장
 - ➤ Tensorflow 1.3 → 최신 버전에 작동하지 않음.
 - https://github.com/carpedm20/multi-speaker-tacotron-tensorflow
 - Tacotron2(2017년12월)
 - r9y9 코드(wavenet vocoder) 공개(2018년1월)

- Rayhane-mamah(2018년4월)
 - ➤ keithito, r9y9 코드를 기반으로 구현된 대표적인 Tacotron 2 구현
 - ➤ Wavenet 구현도 포함
 - https://github.com/Rayhane-mamah/Tacotron-2
- hccho2(2018년12월)
 - ➤ 한국어 Tacotron + Wavenet, Tensorflow 최신 버전으로 실행
 - ➤ 빠른(speed up) convergence
 - https://github.com/hccho2/Tacotron-Wavenet-Vocoder

- Wavenet(2016년9월)
- ibab 코드 공개(2016년9월)
- Tacotron 논문 발표(2017년3월)

Audio Samples

train step: 106000(GTX1080ti-18h)
moon data: 1,125 examples (0.89 hours)
son data: 20,105 examples (19.10 hours)

• 이런 논란은 타코트론 논문 이후에 사라졌습니다.




• 오는 6월6일은 제64회 현충일입니다.





오는 6월6일은 제64회 현충일입니다



Audio Samples(Tacotron2+Griffin-Lim)

train step: 100,000(27h)

moon data: 1,125 examples (0.89 hours) son data: 20,105 examples (19.10 hours)

• 이런 논란은 타코트론 논문 이후에 사라졌습니다.





• 오는 6월6일은 제64회 현충일입니다.





Model	# of trainable_variables()	sec/step (GTX1080ti)
Tacotron 1	7M	0.60
Tacotron 2(Griffin-Lim)	29M	0.98

한국어 Data 준비: 음성/Text

- (약 12초 이하 길이의 음성 파일, Script) 쌍이 필요하다.
- 긴 음성 파일 → 약 12초 이하의 길이로 잘라야 한다.
 - ✓ 문장 단위로 자르지 않아도 된다. 침묵 구간을 기준으로 자른다.
 - ✓ 잘라진 음성 파일과 script의 sync를 맞추는 것은 고단한 작업.
 - ✓ 잘라진 음성 파일 → Google Speech API(STT)로 script 생성
 - ✓ STT로 생성한 script를 원문과 비교하여 수정(수작업 vs programming)

원문	Google STT 결과
세수실적이 좋아	최순실 저 좋아
추경예산안의	조병일 전화해
대폭 늘리겠습니다	아이폰 6s
국회를 존중하면서 쿠키런 존중하며서	
세계 평화와 안보에 기여해 온	세계 평화와 안 보여 귀여워요

한글 Text 분해

- 한글 text를 (초성/중성/종성)으로 나누어진 sequence로 만들어야 한다.
 - ➤ jamo package를 이용하면 된다.


 - ▶ 초성과 종성의 자음은 각각 다른 character로 처리

```
'_': 0, '~': 1, '¬': 2, '¬¬': 3, 'L': 4, '□': 5, '□': 6, '□': 7, '□': 8, '□': 9, 'ш': 10, '人': 11, '从': 12, '○': 13, '太': 14, '\\': 15, '\\:\: 16, '¬¬': 17, '□': 8, '\\:\: 19, '¬¬': 20, '\\:\: 21, '\\:\: 22, '\\:\: 23, '\\:\: 24, '\\:\: 25, '\\:\: 26, '\\:\: 27, '\\:\: 28, '\\:\: 29, '\\:\: 30, '\\:\: 31, '\\:\: 32, '\\:\: 33, '\\:\: 33, '\\:\: 34, '\\:\: 35, '\\:\: 36, '\\:\: 37, '\\:\: 38, '\\:\: 39, '\\:\: 40, '\\:\: 41, '¬': 42, '¬': 43, '\\:\: 44, '\\:\:\: 45, '\\:\: 46, '\\\\:\: 47, '\\:\: 48, '\\:\:\: 49, '\\:\: 50, '\\\\:\: 51, '\\:\:\: 52, '\\:\:\: 53, '\\:\:\: 54, '\\:\:\: 55, '\\\\:\: 56, '\\\\:\: 57, '\\\:\: 58, '\\\\\:\: 59, '\\\\:\: 50, '\\\\\\:\: 70, '\:\:\: 77, '\:\:\: 78, '\:\:\: 79
```

80개 token

소리의 3요소(3 elements of sound)

- 소리의 세기(loudness)
 - 소리의 세기는 물체가 진동하는 폭(진폭)에 의하여 정해지는데, 센(강한) 소리는 진폭이 크고, 약한 소리는 진폭이 작다. 그리고 소리의 세기가 변하더라도 진동수는 달라지지 않으며, 소리의 세기 단위로는 dB(데시벨)을 사용한다.
- 소리의 높이(음정, 고음/저음, frequency or pitch)
 - 소리의 높낮이는 음원의 진동수에 의해 정해지며, 진 동수가 많을수록 높은 소리가 나며, 적을수록 낮은 소 리가 난다. 그리고 단위는 진동수와 같은 단위인 Hz.
 - ✓ Pitch Extraction(Detection) Algorithm
- 소리의 음색(timbre, 맵시)
 - ▶ 소리의 맵시는 파형(파동의 모양)에 따라 구분된다.
 - 사람마다 목소리가 다른 것은 소리의 맵시가 다르기 때문이다.
 - ▶ MFCC는 음색의 특징을 잘 잡아낸다.



어떤 Feature를 사용할 것인가?

MFCC(Mel-frequency cepstral coefficients)

• 음색의 특징을 잘 나타낼 수 있는 feature.


순음




- 음소(phoneme)을 구분한다.
- 배음(overtone, 밑음+부분음) 구조를 잘 파악한다.

배음 🭕

- 음정의 차이는 무시 → 악보를 그리는 데는 부적절.
- 악기의 소리 구분, 사람의 목소리 구분에 적합함.
- MFCC values are not very robust in the presence of additive noise, and so it is common to normalize their values in speech recognition systems to lessen the influence of noise.(wikip edia)
- Tacotron 모델에서는 MFCC보다는 Mel-Spectrogram을 활용한다.
 - ➤ MFCC는 만드는 과정에서 소리의 많은 정보를 잃어버린다. → 복원을 고려해서 Mel-Spectrogram
 - ▶ Linear, Mel-Spectrogram, MFCC 모두 Phase(위상)에 대한 정보를 가지고 있지 않다. → Griffin-Lim으로 복원







Fourier Transform


- 시간에 대한 함수 (or 신호)를 주파수 성분으로 분해하는 작업이다.
- 시간의 함수가 푸리에 변환이 되면, 주파수의 복소함수가 된다.
- 이것의 절대값은 원래 함수를 구성하는 주파수 성분의 양을, 편각은 기본 사인 곡선과의 위상차 (phase offset) 을 나타낸다.

$$\hat{f}\left(\xi
ight) = \int_{-\infty}^{\infty} f(x) \; e^{-2\pi i x \xi} \; dx, \;\;\;\;$$
 (Eq. 1)

$$f(x) = \int_{-\infty}^{\infty} \hat{f}\left(\xi
ight) \, e^{2\pi i x \xi} \, d\xi, \quad ext{(Eq.2)}$$











STFT(Short Time Fourier Transform)






y = librosa.load(audio_clip, sampling_rate)
STFT(y, window_size, hop_size, fft_size)

e.g.
sampling_rate = 24000/1sec
window_size = 1200(=0.05sec)
hop_size = 300 → 길이 결정
fft_size = 2048 → output 크기 결정

audio_clip(1D data) → 2D data (T, fft_size/2 +1)

STFT(Short Time Fourier Transform)


$$y = \sin(100 \times 2\pi x) + 0.5\sin(160 \times 2\pi x)$$




```
# STFT
import librosa
import matplotlib.pyplot as plt
N = 1000
T = 1.0 / N
x = np.linspace(0.0, N*T, N) # 0~10 AFOOM N(1000) 7% sampling

y = np.sin(100.0 * 2.0*np.pi*x) + 0.5*np.sin(160.0 * 2.0*np.pi*x)
yf = librosa.stft(y,n_fft=2048) # n_fft = 2048(default)
plt.show()
```

n_fft가 output 크기 결정






From Audio To Mel-spectrogram Raw Audio Clip(73512) Padded Audio(69900) sr = 24000 $233 \times \text{hop_size}(300) = 69900$ Silence Trim(69880) 69880/300 = 232.93 STFT(233,1025) $fft_size = 2048 \rightarrow fft_size/2 + 1$ Griffin-Lim Mel_Basis곱하기(233,80) ABS(233,1025) num_mels=80 (1025,80)amp_to_db amp_to_db normalization 방식에 ref_level_db 빼기 ref level db 빼기 따라 [0,1] 또는 [0,4], [-4,4] 의 값을 가질 수 있다. <u>normalize</u> normalize (linear) spectrogram mel-spectrogram 19


Mini-Batch Data 생성

- (audio, text, mel-spectrogram, linear-spectrogram, tokens, ...) 묶어 npz로 미리 만들어 놓는다.
- DataFeeder Class를 만들어, training 할 때 data를 공급한다.
 - ➤ Mini-Batch(N개. e.g. 32) data를 적당한 개수(M개. e.g. 32) 만큼 만들어 Queue에 쌓는 방식을 사용.
 - ➤ N x M 개의 data를 길이로 정렬 후, N개씩 나누어 공급한다
 - → padding 최소화
 - (input_data, input_length, mel_target, linear_target, speaker_id)
 - ➤ Speaker별로 feed되는 data의 비율이 동일하게 처리
 - ➤ hyper parameter가 바뀌면 data를 새로 만들어야 함. (eg. hop_size)

2. RNN, Attention

Tensorflow BasicRNNCell/dynamic_rnn






$$h_t = \tanh (x_t U + h_{t-1} W + b)$$
$$= \tanh ([x_t | h_{t-1}] Y + b)$$

Tensorflow 내부에서는 U,W가 각각 잡히지 않고, 묶어서 Y 하나만 잡힌다.

dynamic_rnn은 teacher-forcing으로 구현은 가능하나, free-running(inference)에는 불편한 점이 많다.


Sample Code(C) 참조

Tensorflow dynamic_decode




BasicDecoder


- BasicDecoder의 step함수는 cell, Helper를 결합하여 (outputs, next_state, next_inputs, finished)를 return한다.
- cell이나 Helper가 customization되어 있다면, BasicDecoder도 customization해야 한다.



Tensorflow AttentionMechanism



Attention



- score를 계산하는 과정에 encoder hidden state, decoder hidden sate 모두 반영된다.
- Bahdanau Attention과 Luong Attention은 score 계산방식에서만 차이가 있다.

용어:

- score
- alignment
- context
- attention
- $[h_1, h_2, \dots, h_{T_e}]$: encoder hidden state, $h_i \in R^{eh}$
- s_i : decoder hidden state, $s_i \in R^{dh}$

$$\rightarrow e_i = [e_{i1}, e_{i2}, \cdots, e_{iT_e}]$$
: score

- For decoder time → softmax
 - \rightarrow alignment (weight), $a_{ii} \in R$

$$\rightarrow C_{i} = \sum_{j=1}^{T_{e}} a_{ij} h_{j} : context$$

→ attention vector

step i

Bahdanau & Luong Attention

 h_i : encoder hidden state, s_i : decoder hidden state

2: Luong

3: Bahdanau

$$score(s_i, h_j) = e_{ij} = \begin{cases} h_j s_i^T & \text{1. dot product attention} \\ (h_j Y_a) s_i^T & \text{2. general dot product attention} \\ v_a^T \tanh(Y_a[s_i|h_j]^T) & \text{3. concat(Bahdanau), additive attention} \end{cases}$$

$$= v_a^T \tanh\left([W_q^T|W_m^T] \begin{bmatrix} s_i^T \\ h_j^T \end{bmatrix}\right)$$

$$= \tanh\left([s_i|h_j] \begin{bmatrix} W_q \\ W_m \end{bmatrix}\right) v_a$$

$$= \tanh\left(s_i W_q + h_j W_m\right) v_a$$

_bahdanau_score

$$e_i = [e_{i1}, \cdots, e_{iT_e}]$$

$$\alpha_i = softmax(e_i) = [\alpha_{i1}, \cdots, \alpha_{iT_e}] \leftarrow \text{alignment}$$

alignment를 AttentionMechanism에서 계산하고, 그 결과를 받아서 AttentionWrapper내에서 _compute_attention를 이용하여 최종 attention을 계산한다.

$$c_i = \sum_{j=1}^{T_e} \alpha_{ij} h_j \leftarrow \text{context}, N \times N_{eh}$$

Tensorflow-AttentionMechanism


- Bahdanau Attention → tf.contrib.seq2seq.BahdanauAttention
- Luong Attention → tf.contrib.seq2seq.LuongAttention

```
attention_mechanism
= tf.contrib.seq2seq.BahdanauAttention(num_units=11,
memory=encoder_outputs,
memory_sequence_length=input_lengths)
```

TIP


```
memory = encoder hidden state → memory_layer → key query = decoder hidden state → query_layer → processed_query
```

AttentionWrapper & AttentionWrapperState



AttentionWrapper

tf.contrib.seq2seq.AttentionWrapper(cell, attention_mechanism, attention_layer_size=13)




<u>AttentionWrapper</u>

```
AttentionWrapper(cell,attention mechanism)
                                                                      cell은 BasicRNNCell, BasicLSTMCell같은 RNNCell이며,
                                                                       reture되는 cell output과 next cell state는 같은 값이다.
   ★ self.__init__(cell, attention_mechanism)
   ★ self.call( input, state(AttentionWrapperState) )
        cell_output, next_cell_state = cell(input,state.cell_state)
                                                   cell_state는 보통의
                                                   hidden state
        compute attention(attention mechanism, cell output, state.attention state)
            alignments, next attention state = attention mechanism(cell output, state.attention state)
                                                                    alignment와 next attention state는 같은 값이다.
            return attention, alignments, next attention state
        return cell_output, next_state(AttentionWrapperState)
                                                                  next state = AttentionWrapperState(
                                                                   cell state = next cell state,
                                                                   attention = attention,
                                                                  attention_state = next_attention_state,
                                                                   alignments = alignments)
                                                                                                                     31
```

MonotonicAttention

- tf.contrib.seq2seq. BahdanauMonotonicAttention
- tf.contrib.seq2seq. LuongMonotonicAttention





3. Tacotron 분석

Encoder


'국민과 함께하는'

- → ['¬', '¬', '¬', '¬', 'L', '¬', '사', ' , 'ㅎ', 'ㅏ', 'ㅁ', 'ㄲ', '╢', 'ㅎ', 'ㅏ', 'ㄴ', 'ㅡ', 'ㄴ']
- **→** [2, 34, 42, 8, 41, 45, 2, 30, 79, 20, 21, 57, 3, 26, 20, 21, 4, 39, 45]
- → Character embedding






Decoder



- ConcatOutputAndAttentionWrapper: [attention(256),output(256)] concat
 - → RNNWrapper Class를 만들 수 있어야 한다.



Tensorflow RNNCell-Wrapper 활용




```
class MyBasicRNNWrapper(RNNCell):
   # property(output size, state size) 2개와 call을 정의하면 된다.
   def init (self, cell, name=None):
       super(MyBasicRNNWrapper, self). init (name=name)
       self.cell = cell
   @property
   def output size(self):
       return self.cell.output size
   @property
   def state_size(self):
       return self.cell.state size
   def call(self, inputs, state):
       # 필요한 작업1: inputs, state를 이용하여 필요한 작업을 수행하여 self.cell에 넘겨줄 새로운 inputs, state를 만든다.
       cell output, next state = self.cell(inputs, state)
   # 필요한 작업2: self.cell이 return한 cell outpus, next state를 가공하여 return 값을 만든다.
                                                                                                    37
       return cell_output, next_state
```

Tensorflow RNNCell-Wrapper 활용

- Tensorflow에 구현되어 있는 RNNWrapper class
 - OutputProjectionWrapper
 - ➤ InputProjectionWrapper
 - > ResidualWrapper

```
def call(self, inputs, state):
    cell_output, next_state = self.cell(inputs, state)
    cell_output = inputs + cell_output # residual rnn
    return cell_output, next_state
```


```
def call(self, inputs, state):
    fc_outputs = tf.layers.dense(inputs,units=5,name='myFC') # FC layer
    cell_output, next_state = self.cell(fc_outputs,state)
    cell_output = inputs + cell_output # residual rnn
    return cell_output, next_state
```



- Mel-Spectrogram을 CBHG layer에 넣어, Linear-Spectrogram을 만든다.
- 이 CBHG layer는 encoder에 있는 CBHG와 같은 layer지만, hyper parameter가 다르다.
- CBHG를 training할 때, 어떤 Mel-Spectrogram을 입력으로 사용할 것인가?

 ▶ 이전 단계에서 만들어낸 Mel-Spectrogram vs Ground Truth Mel-Spectrogram
- Tacotron 모델이 최종적으로 Linear-Spectrogram을 만들면, Griffin-Lim Algorithm을 이용해서 audio를 생성한다.
- Loss = | mel_output mel_target | + | linear_output linear_target |


Multi-Speaker Model로 확장(DeepVoice 2)



- speaker embedding vector를 network 중간-중간에 concat하는 방식의 모델도 있다.
- DeepVoice2 논문에는 Tacotron 모델을 Multi-Speaker 모델로 확장하는 방법을 제시하고 있다. 여기서는 speaker embedding vector를 RNN의 initial state로 넣어주는 방식을 사용한다.


Speaker Embedding → Speaker별 data 불균형 해소

- 각 speaker별로 embedding vector(dim 16)을 먼저 만든 후, FC를 거치면서 필요한 크기로 만든 다음, activation function으로 softsign 함수를 적용한다.
- softsign함수는 tanh 대신 사용되었다고 보면 된다.
- 논문에서는 언급되지 않았지만, speaker embedding을 만들지 않고, initial state 자체를 embedding vector로 만들 수도 있다.



Tacotron2

- 2017년 12월 발표
- CBHG 제외
- Location Sensitive Attention, Residual Layer 추가
- Stop Token 도입
- Vocoder로 Modified Wavenet사용: MoL
- L2 regularization
- 대표적인 구현 코드: Rayhane Mama



4. Appendix

Sample Code(A)

```
def dynamic decode test():
    vocab size = 5
   SOS token = 0
   EOS token = 4
   x data = np.array([[SOS token, 3, 1, 2, 3, 2],[SOS token, 3, 1, 2, 3, 1],[SOS token, 1, 3, 2, 2, 1]], dtype=np.int32)
   y data = np.array([[1,2,0,3,2,EOS token],[3,2,3,3,1,EOS token],[3,1,1,2,0,EOS token]],dtype=<math>np.int32)
    print("data shape: ", x data.shape)
   sess = tf.InteractiveSession()
    output dim = vocab size
   batch size = len(x data)
   hidden dim =6
   num layers = 2
    seq length = x data.shape[1]
    embedding dim = 8
   state tuple mode = True
   init state flag = 0
   init = np.arange(vocab size*embedding dim).reshape(vocab size,-1)
    train mode = True
   with tf.variable scope('test', reuse=tf.AUTO REUSE) as scope:
       # Make rnn
       cells = []
       for in range(num layers):
            #cell = tf.contrib.rnn.BasicRNNCell(num units=hidden dim)
           cell = tf.contrib.rnn.BasicLSTMCell(num units=hidden dim, state is tuple=state tuple mode)
            cells.append(cell)
        cell = tf.contrib.rnn.MultiRNNCell(cells)
        #cell = tf.contrib.rnn.BasicRNNCell(num units=hidden dim)
        embedding = tf.get variable("embedding", initializer=init.astype(np.float32),dtype = tf.float32)
        inputs = tf.nn.embedding lookup(embedding, x data) # batch size x sea length x embedding dim
       Y = tf.convert to tensor(y data)
```

```
if True:
   cell = tf.contrib.rnn.OutputProjectionWrapper(cell,13)
   cell = tf.contrib.rnn.OutputProjectionWrapper(cell,19)
if init state flag==0:
     initial state = cell.zero state(batch size, tf.float32) #(batch size x hidden dim) x layer 개수
else:
    if state tuple mode:
       h0 = tf.random_normal([batch_size,hidden_dim]) #h0 = tf.cast(np.random.randn(batch_size,hidden_dim),tf.float32)
       initial state=(tf.contrib.rnn.LSTMStateTuple(tf.zeros like(h0), h0),) + (tf.contrib.rnn.LSTMStateTuple(tf.zeros like(h0)), tf.zeros like(h0)),)*(num layers-1)
    else:
        h0 = tf.random_normal([batch_size,hidden_dim]) #h0 = tf.cost(np.random.randn(batch_size,hidden_dim),tf.float32)
        initial state = (tf.concat((tf.zeros like(h0),h0), axis=1),) + (tf.concat((tf.zeros_like(h0),tf.zeros_like(h0)), axis=1),) * (num_layers-1)
if train mode:
   helper = tf.contrib.seq2seq.TrainingHelper(inputs, np.array([seq length]*batch size))
   helper = tf.contrib.seq2seq.GreedyEmbeddingHelper(embedding, start tokens=tf.tile([SOS token], [batch size]), end token=EOS token)
output layer = Dense(output dim, name='output projection')
decoder = tf.contrib.seq2seq.BasicDecoder(cell=cell,helper=helper,initial state=initial state,output layer=output layer)
# maximum_iterations를 설정하지 않으면, inference에서 EOS토론을 만나지 못하면 무한 루프에 빠진다
# Last state = num Layers 만큼 나온다.
outputs, last state, last sequence lengths = tf.contrib.seq2seq.dynamic decode(decoder=decoder,output time major=False,impute finished=True,maximum iterations=10)
weights = tf.ones(shape=[batch_size,seq_length])
loss = tf.contrib.seq2seq.sequence loss(logits=outputs.rnn output, targets=Y, weights=weights)
```

- input_dim=8
- hidden_dim=6

(input dim+hidden dim) x (hidden dim x 4): 첫번째 LSTM

(hidden dim+hidden dim) x (hidden dim x 4): 두번째 LSTM <tf.Variable 'test/embedding:0' shape=(5, 8) dtype=float32 ref>, <tf. Variable 'test/decoder/output projection wrapper/out ut projection wrapper/ multi rnn cell/cell 0/basic lstm cell/kernel:0' shape=(14, 24) dtype=float32 ref>, tf. Variable 'test/decoder/output projection wrapper/output projection wrapper/ multi rnn cell/cell 0/basic lstm cell/bias:0' shape=(24,) dtype=float 2 ref>, **FC(13)** <tf. Variable 'test/decoder/output projection wrapper/output projection wrapper/ multi rnn cell/cell 1/basic lstm cell/kernel:0' shape=(12, 24)/dtype=float32 ref>, <tf.Variable 'test/decoder/output projection wrapper/output projection wrapper/</pre> multi rnn cell/cell 1/basic lstm cell/bias:0' shape=(24,) dtype=float32 ref>, <tf. Variable 'test/decoder/output projection wrapper/output projection wrapper/kernel:0' shape=(6, 13) dtype=float32 ref>, <tf. Variable 'test/decoder/output projection wrapper/output projection wrapper/bias:0' shape=(13,) dtype=float32 ref>, <tf. Variable 'test/decoder/output projection wrapper/kernel:0' shape=(13, 19) dtype=float32 ref>, <tf.Variable 'test/decoder/output projection wrapper/bias:0' shape=(19,) dtyre=float32 ref>, <tf. Variable 'test/decoder/output projection/kernel:0' shape=(19, 5) dtype=float32 ref>, <tf.Variable 'test/decoder/output projection/bias:0' shape=(5,) dxype=float32 ref>] FC(19) **FC(5)**

Sample Code(B)

```
def attention test():
    # BasicRNNCell을 single로 當아 attention 母岳
    vocab size = 5
   SOS token = 0
    EOS_token = 4
    x_data = np.array([[SOS_token, 3, 1, 2, 3, 2],[SOS_token, 3, 1, 2, 3, 1],[SOS_token, 1, 3, 2, 2, 1]], dtype=np.int32)
   y data = np.array([[1,2,0,3,2,EOS token],[3,2,3,3,1,EOS token],[3,1,1,2,0,EOS token]],dtype=np.int32)
    print("data shape: ", x_data.shape)
    sess = tf.InteractiveSession()
   output dim = vocab size
   batch size = len(x_data)
   hidden dim =6
    seq length = x data.shape[1]
    embedding dim = 8
   init = np.arange(vocab_size*embedding_dim).reshape(vocab_size,-1)
    train mode = True
    alignment history flag = True # True이면 initial state나 last state를 sess.run 라면 안된. alignment history가 function이기 때문에...
    with tf.variable scope('test',reuse=tf.AUTO REUSE) as scope:
        # Make rnn cell
        cell = tf.contrib.rnn.BasicRNNCell(num units=hidden dim)
        embedding = tf.get variable("embedding", initializer=init.astype(np.float32),dtype = tf.float32)
        inputs = tf.nn.embedding lookup(embedding, x data) # batch size x sea length x embedding dim
        Y = tf.convert to tensor(y data)
        #encoder outputs = tf.ones([batch size, 20, 30])
        encoder_outputs = tf.convert_to_tensor(np.random.normal(0,1,[batch_size,20,30]).astype(np.float32)) # 20: encoder sequence length, 30: encoder hidden dim
        input lengths = [20]*batch size
```

encoder_hidden_state: (N,encoder_length,encoder_hidden_dim)

```
# attention mechanism # num units = Na = 11
   attention mechanism = tf.contrib.seq2seq.BahdanauAttention(num units=11, memory=encoder outputs,memory sequence length=input lengths,normalize=False)
   #attention mechanism = tf.contrib.seg2seg.BahdanauMonotonicAttention(num units=11, memory=encoder outputs, memory sequence length=input lengths)
   # output attention = True(default) ==> 0/2 output으로 attention() 나가고, False()/전 cell의 output() 나간다
   # attention layer size = N L
   cell = tf.contrib.seq2seq.AttentionWrapper(cell, attention mechanism, attention layer size=13,alignment history=alignment history flag,output attention=True)
   initial state = cell.zero state(batch size, tf.float32) #(batch size x hidden dim) x Layer 州수
   if train mode:
      helper = tf.contrib.seq2seq.TrainingHelper(inputs, np.array([seq length]*batch size))
   else:
      helper = tf.contrib.seq2seq.GreedyEmbeddingHelper(embedding, start_tokens=tf.tile([SOS_token], [batch_size]), end_token=EOS_token)
   output layer = Dense(output dim, name='output projection')
   decoder = tf.contrib.seg2seg.BasicDecoder(cell=cell,helper=helper,initial state=initial state,output layer=output layer)
   # maximum iterations를 설정하지 않으면. inference에서 EOS토론을 만나지 못하면 무한 루프에 쌔진다
   outputs, last state, last sequence lengths = tf.contrib.seq2seq.dynamic decode(decoder=decoder,output time major=False,impute finished=True,maximum iterations=10)
   weights = tf.ones(shape=[batch size.seg length])
   loss = tf.contrib.seq2seq.sequence loss(logits=outputs.rnn output, targets=Y, weights=weights)
                                              (input dim+decoder hidden dim+attention layer size) x (decoder hidden dim)
         (encoder hidden_dim x num_units)
                                                                                                (decpcer_hidden_dim x num_units)
<tf.Variable 'test/embedding:0' shape=(5, 8) dtype=float32 ref>,
<tf. Variable 'test/memory layer/kernel:0' shape=(30, 11) dtype=float32 ref>,
<tf. Variable 'test/decoder/attention wrapper/basic rnn cell/kernel:0' shape=(27, 6) dtype=float32 ref>,
<tf. Variable 'test/decoder/attention wrapper/basic rnn cell/bias:0' shape=(6,) dtype=float32 refs>,
<tf. Variable 'test/decoder/attention wrapper/bahdanau attention/query layer/kernel:0' shape=(6, 11) dtype=float32 ref>,
<tf. Variable 'test/decoder/attention wrapper/bahdanau attention/attention v:0' shape=(11,) dtype=float32 ref>,
<tf.Variable 'test/decoder/attention wrapper/attention layer/kernel:0' shape=(36, 13) Atype=float32 ref>,
<tf.Variable 'test/decoder/output projection/kernel:0' shape=(13, 5) dtype=float32 ref>,
<tf. Variable 'test/decoder/output projection/bias:0' shape=(5,) dtype=float32 ref>]
                                                                                                         (num units)
```

(encoder_hidden_dim+decoder_hidden_dim) x attention_layer_size

정리: for decoder time step i

(N,27)

(27,6)

$$(N.6) s_i = \tanh\left(\overline{[x_i|a_{i-1}|s_{i-1}]}W + b\right)$$

$$(N,20) e_i = \tanh\left([h_1,\cdots,h_{T_e}]W_m + \underline{s_i}W_q\right)v_a$$

$$(N,20)$$
 $a_i = \operatorname{softmax}(e_i)$

$$c_i = \sum_{i=1}^{\infty} a_{ij} h_j$$

(N,20,30) (30,1 1)

덧셈이 되기 위해서는 뒤쪽의 (N,11)을 expand_dims를 통해 (N,1,11)로 변환해야 한다.

Tensorflow tensor연산으로 표현하면 어떻게 되나?


Sample Code(C)


```
# Sample Code C
batch_size= 5
hidden_dim= 8

input = tf.placeholder(tf.float32,shape=[None,None,2])
cell = tf.contrib.rnn.BasicRNNCell(num_units=hidden_dim)
initial_state = cell.zero_state(batch_size, tf.float32)
outputs, states = tf.nn.dynamic_rnn(cell,input,initial_state=initial_state,dtype=tf.float32)
```

```
[<tf.Variable 'rnn/basic_rnn_cell/kernel:0' shape=(10, 8) dtype=float32_ref>, <tf.Variable 'rnn/basic_rnn_cell/bias:0' shape=(8,) dtype=float32_ref>]
```







Tensorflow-Dropout

tf.layers.dropout

```
tf.layers.dropout(
    inputs,
    rate=0.5,
    noise_shape=None,
    seed=None,
    training=False,
    name=None
)
```

tf.nn.dropout

```
tf.nn.dropout(
    x,
    keep_prob,
    noise_shape=None,
    seed=None,
    name=None
)
```



• keithito 코드에서는 2018년8월 31일 bug 수정

dec prenet outputs = DecoderPrenetWrapper(GRUCell(hp.attention state size), speaker embed, is training, hp.dec prenet sizes, hp.dropout prob) # single: attention size = 128 if hp.attention type == 'bah mon': attention mechanism = BahdanauMonotonicAttention(hp.attention size, encoder outputs,normalize=False) elif hp.attention type == 'bah mon norm': attention mechanism = BahdanauMonotonicAttention(hp.attention size, encoder outputs,normalize=True) elif hp.attention type == 'bah norm': attention mechanism = BahdanauAttention(hp.attention size, encoder outputs, normalize=True) elif hp.attention type == 'luong scaled': attention mechanism = LuongAttention(hp.attention size, encoder outputs, scale=True) Prenet elif hp.attention type == 'luong': attention mechanism = LuongAttention(hp.attention size, encoder outputs) elif hp.attention type == 'bah': attention mechanism = BahdanauAttention(hp.attention size, encoder outputs) elif hp.attention type.startswith('ntm2'): **AttentionWrapper**

initial cell state=attention rnn init state,alignment history=True,output attention=False) # output attention=

attention mechanism = NTMAttention2(hp.attention size, encoder outputs, shift width=shift width)


attention cell = AttentionWrapper(dec prenet outputs, attention mechanism, self.is manual attention, self.manual alignments,

raise Exception(" [!] Unkown attention type: {}".format(hp.attention type))


DecoderPrenetWrapper, attention_mechanisma assa AttentionWrappera BED.

shift width = int(hp.attention type.split('-')[-1])

else:



Prenet



Tacotron Training 과정

9월	- Single speaker 모델 시도. 왜 안되지? - Attention Model로 MonotonicAttention적용. alignment합이 왜 1이 아닌가? - librosa version 0.5.1 vs 0.6.1 - tensorflow 1.8로 변경 - dropout bug발견 → keith ito 코드와 비교 - AttentionWrapper와 PrenetWrapper 순서 바로 잡음
10월	 Padding에 Attention 가지 않도록 ■ batch_size = 1로 변경? ■ Attention class로 customization시도 → Tensorflow내에 이미 구현되어 있다는 것 발견 수작업으로 script 수정 → Data 품앗이 Tacotron2 모델의 stop token 적용, location sensitive attention, GMM attention 시도
11월	- Mel Spectrogram 생성방식 수정